Chapitre 3 Théorie des syntaxes abstraites

Idées

- syntaxe abstraite = ensemble d'arbres (AST)
- sémantique/interprétation d'un AST = parcours récursif de l'AST
- Ici, arbres codés comme des mots particuliers (comme dans n'importe quel langage de prog).
  NB : point de vue TL et pas théorie des graphes...
  codage des arbres par notation préfixe (le +simple).

Pour commencer : des exemples !

Signature d'un ensemble d'AST pour expr. rég. sur $\{a, b\}$

Signature = liste de *constructeurs* (opérateurs) avec leur type.

nom du type des expr. rég. sur $\{a, b\}$	$\texttt{Rexp}$
constants	pour $c \in \{\texttt{void}, \texttt{epsilon}, a, b\}$, $c : \texttt{Rexp}$
unaire	$\texttt{star} : \texttt{Rexp} \to \texttt{Rexp}$
binaires	pour $c \in \{\texttt{u}, \texttt{dot}\}$, $c : \texttt{Rexp} \times \texttt{Rexp} \to \texttt{Rexp}$

Exo 3.1† Dessiner l'AST de l'expr. rég. "$b + (a.a.(\epsilon + a)^*)$".
Coder cet AST en notation préfixe (suite d'appels des constructeurs sans parenthèse).
Exo 3.2† Dessiner l'AST encodé par le mot "$\texttt{star u dot } a\ b\ a$", en notation *naturelle*, puis en **notation étendue**, où chaque nœud est un type d'AST et a un enfant supplémentaire (à gauche) : le nom du constructeur.
Exo 3.3† Donner une BNF qui définit cette notation préfixe d'AST.

Récursion structurelle sur une structure d'AST

Idée pour "*définir simplement*" une fonction de $\texttt{Rexp} \to D$, choisir

- constantes A_c dans D, pour $c \in \{\texttt{void}, \texttt{epsilon}, a, b\}$.
- une fonction $A_{\texttt{star}} \in D \to D$.
- deux fonctions $A_{\texttt{u}}$ et $A_{\texttt{dot}}$ de $D \times D \to D$,

Exo 3.4† Appliquer cette idée avec

- $D \stackrel{def}{=} \mathcal{P}(V^*)$ pour la sémantique des $\texttt{Rexp}$ (comme ensemble de mots).
- $D \stackrel{def}{=}$ ensemble des automates finis (non-déterministes avec ϵ-transitions) pour générer l'automate associé à une $\texttt{Rexp}$.
  Calculer l'automate de $A_{\texttt{dot}}(A_a, A_a)$ avec vos définitions.

Récursion sur AST par système d'attributs

Exemple de système d'attributs (sur `Rexp`)
Principe : BNF décorée avec *attributs*.
Exprime calculs sur l'arbre.

Typage de l'attribut : $\texttt{Rexp}\!\uparrow\!\mathcal{P}(\{a,b\}^*)$.

$$\begin{array}{rcll}
\texttt{Rexp}\!\uparrow\!\ell & ::= & \texttt{void} & \ell := \emptyset \\
 & | & \texttt{epsilon} & \ell := \{\epsilon\} \\
 & | & a & \ell := \{a\} \\
 & | & b & \ell := \{b\} \\
 & | & \texttt{u Rexp}\!\uparrow\!\ell_1\ \texttt{Rexp}\!\uparrow\!\ell_2 & \ell := \ell_1 \cup \ell_2 \\
 & | & \texttt{dot Rexp}\!\uparrow\!\ell_1\ \texttt{Rexp}\!\uparrow\!\ell_2 & \ell := \ell_1.\ell_2 \\
 & | & \texttt{star Rexp}\!\uparrow\!\ell_1 & \ell := \ell_1^*
\end{array}$$

Exo 3.5† Dessiner la propagation de l'attribut sur l'AST (en notation étendu) encodé par le mot "`star u dot` *a b a*".

Deux modes de passage des attributs

- attribut ↑ dit "synthétisé" (propagé du fils vers le père)
  ⇒ correspond à un "résultat" de l'appel récursif.
- attribut ↓ dit "hérité" (propagé du père vers le fils)
  ⇒ correspond à un paramètre d'entrée de l'appel récursif.

Exo 3.6† Soient les arbres binaires de sorte `B` engendrés par constructeurs "$\texttt{l} : \texttt{B}$" et "$\texttt{n} : \texttt{B} \times \texttt{B} \rightarrow \texttt{B}$".
Dans chacun des cas ci-dessous, définir système d'attributs qui :

1. compte le nombre de feuilles (noeuds `l`) dans l'arbre.
2. indique si toutes les feuilles de l'arbre sont à une profondeur h ou $h-1$, avec h paramètre donné (par convention, feuille de hauteur 0).

Appliquer les algorithmes sous-jacents sur les exemples ci-dessous en dessinant la propagation d'attributs sur chaque nœuds :

1. `n l n n l l n l l`
2. `n n l l n n l l n l l`

pour Q2, on prendra h valant à la racine 2, puis ensuite 3.

Exercices

Exo 3.7† On considère le système donné à la tâche 4 du TP.

1. Soit p l'AST "*and var* 1 *neg var* 2".
   Calculer le r retourné une dérivation de "$p{\downarrow}1{\uparrow}r$".
2. Calculer la NNF attendue pour "`-(((t&1)>(-2|f))&3)`".

Exo 3.8 Exo 3 de mars 2018.

Applications des systèmes d'attributs à la programmation

- Interpréteur sur des arbres : cf. tâche 4 du TP.
- Interpréteur sur des mots :
  programmation d'un analyseur en notation préfixe.
  ⇒ la suite de ce cours (et aussi tâche 5 du TP).

Chapitre 3 Théorie des syntaxes abstraites

Plan de la section 3.2

Terminologie de cette définition mathématique

- Définition inspirée de notion de "*termes*" en logique :
  1 arbre de syntaxe
  = 1 terme
  = 1 mot dans alphabet des *constructeurs* d'arbres
  = 1 mot en **notation préfixe** (Łukasiewicz 1924)

  cf. école polonaise de logique des années 1920-1930 (Tarski).
- "Forme" des termes définie par *signature multisortée*.
  1 sorte = 1 nom de type d'arbre = 1 catégorie syntaxique.
  On peut avoir +sieurs sortes.
- Syntaxe abstraite = *langage de termes* engendré par une *signature multisortée* fixée.

NB : notation préfixe aussi une syntaxe concrète qui peut suffire pour fichiers binaires (non lus par humain).

Définition des signatures multisortées

Une signature multisortée Σ est un quadruplet $(\mathcal{C}, \mathcal{S}, s_{princ}, \mathrm{type})$ avec

- $\mathcal{C}$ un ensemble *dénombrable* de "*constructeurs*".
  (vocabulaire du langage des termes qui représentent des arbres)
- $\mathcal{S}$ un ensemble *fini* de symboles de "*sortes*".
  (1 sorte = nom d'un type d'arbre)
- s_{princ} de $\mathcal{S}_{int}$ = "*la sorte principale*".
- type application de $\mathcal{C} \rightarrow \mathcal{S}^+$
  NB "$\mathrm{type}(c) = s_1 . \cdots . s_{n+1}$" formalise la notation :
  $$c : s_1 \times \ldots \times s_n \rightarrow s_{n+1}$$

Définition des termes sur signature Σ

Système d'équation algébrique associée à Σ

- une variable X_s pour chaque sorte $s \in S$
- pour chaque sorte s une équation

$$X_s = \bigcup_{c:s_1\times\ldots\times s_n\to s} \{c\}.X_{s_1}.\cdots.X_{s_n}$$

Langage des termes de sorte s
On note $(T_\Sigma(s))_{s\in S}$ le plus petit point-fixe de ce système d'équations.

Syntaxe abstraite $= T_\Sigma(s_{princ})$ (abbrev. T_Σ)

Exemple de signature Σ_{TP} pour **Prop** (similaire au TP)

- $\mathcal{S} \stackrel{def}{=} \{\texttt{Pos}, \texttt{Prop}\}$ avec $s_{princ} \stackrel{def}{=} \texttt{Prop}$.
- $\mathcal{C} \stackrel{def}{=} \mathbb{N}\backslash\{0\} \uplus \{\texttt{true}, \texttt{false}, \texttt{var}, \texttt{neg}, \texttt{and}, \texttt{or}\}$.
- type défini par :
  - pour $c \in \mathbb{N}\backslash\{0\}$, $c : \texttt{Pos}$ (constructeurs de la sorte externe).
  - pour $c \in \{\texttt{true}, \texttt{false}\}$, $c : \texttt{Prop}$.
  - $\texttt{var} : \texttt{Pos} \to \texttt{Prop}$.
  - $\texttt{neg} : \texttt{Prop} \to \texttt{Prop}$.
  - pour $c \in \{\texttt{and}, \texttt{or}, \texttt{implies}\}$, $c : \texttt{Prop} \times \texttt{Prop} \to \texttt{Prop}$.

Exo 3.9† Donner le système d'équations algébrique associé à cette signature Σ_{TP}. Exprimer ce système en syntaxe BNF avec *attributs* : pour se ramener à un ensemble *fini* de constructeurs, on placera $\mathbb{N}\backslash\{0\}$ en attribut synthétisé du constructeur var.

Exo 3.10† Définir une signature pour NNF avec sortes **Nnf** et **Ncst**, puis la BNF associée

Fonctions constructeurs (au sens des AST)

Étant donné Σ une signature multisortée et $c \in \mathcal{C}$ tel que $c : s_1 \times \ldots \times s_n \to s$

Définition La *fonction constructeur* de c, notée $\bar{c}$, est la *fonction totale* de $(\mathcal{C}^+)^n \to \mathcal{C}^+$ définie par

$$\bar{c}(t_1, \ldots, t_n) \stackrel{def}{=} c.t_1.\cdots.t_n$$

Exo 3.11 Montrer $n \geq 2 \Rightarrow \bar{c}$ pas injective sur $\overbrace{\mathcal{C}^+ \times \ldots \times \mathcal{C}^+}^{n} \to \mathcal{C}^+$

Exo 3.12 Montrer les deux lemmes suivants.

Lemme du préfixe unique Pour tout mot u de $\mathcal{C}^*$, il existe *au plus un* préfixe t de u qui vérifie il existe $s \in S$ tq $t \in T_\Sigma(s)$.

Corollaire (injectivité des constructeurs)
$\bar{c}$ est *injective* sur $T_\Sigma(s_1) \times \ldots \times T_\Sigma(s_n) \to T_\Sigma(s)$.
NB : justifie *unicité* du "parenthésage implicite" !

Plan de la section 3.2

Motivation

Systèmes d'attributs : méta-syntaxe pour définir *simultanément* syntaxe abstraite + sémantique

Leur méta-sémantique : 1 signature Σ et sa Σ-sémantique (thm de récursion structurelle)

- Systèmes d'attributs inventés par Knuth en 1967 (en fait plus généraux que ceux présentés ici).
  une notation pratique pour *concevoir* un nouveau langage : on conçoit l'AST et la sémantique simultanément, *avant* la syntaxe concrète.
- Σ-sémantique = une formalisation mathématique simple de la notion de sémantique (ou d'interpréteur) d'une structure d'AST.

Définition des Σ-sémantiques (ou Σ-algèbres, Σ-structures)

Définition Σ-sémantique = un couple $((D_s)_{s\in\mathcal{S}},(A_c)_{c\in\mathcal{C}})$ où :

- $(D_s)_{s\in\mathcal{S}}$ est une suite d'ensembles ("domaines sémantiques").
- pour tout $c\in\mathcal{C}$, si $c : s_1\times\ldots\times s_n\to s$,
  alors A_c fonction totale de $D_{s_1}\times\ldots\times D_{s_n}\to D_s$.
  (A_c "action sémantique").

Théorème de la récursion structurelle
Étant donné une Σ-sémantique, il existe une unique

$$[\![.]\!] \text{ fonction totale de } (\bigcup_{s\in\mathcal{S}} T_\Sigma(s)) \to (\bigcup_{s\in\mathcal{S}} D_s)$$

telle que :

- pour tous $s\in\mathcal{S}$ et $t\in T_\Sigma(s)$, on a $[\![t]\!]\in D_s$
- $[\![c.t_1.\cdots.t_n]\!] = A_c([\![t_1]\!],\ldots,[\![t_n]\!])$.

Rem on peut voir $[\![.]\!]$ comme ensemble fini de fonctions *mutuellement récursives* notées $[\![.]\!]_s\in T_\Sigma(s)\to D_s$ pr tt s de S.

(Méta)syntaxe et sémantique des BNF attribuées d'AST

BNFs attribuées d'AST :
1 (méta)notation pour définir signature Σ et sa Σ-sémantique

Principe

- non-terminal = sorte
- Chaque profil de non-terminal "$s{\downarrow}E_1\ldots{\downarrow}E_m{\uparrow}E'_1\ldots{\uparrow}E'_{m'}$" définit $D_s \stackrel{def}{=} E_1\times\ldots\times E_m\to E'_1\times\ldots\times E'_{m'}$.
- L'équation (avec attributs) du non-terminal s définit à la fois le typage des constructeurs d'image s et l'action sémantique associée à ces constructeurs.

Les 4 diapos suivantes définissent :

- la (méta)syntaxe des équations
- la (méta)sémantique des équations avec attributs

Les "alternatives" d'une équation vues comme des "règles"

Pour simplifier formalisation, abstraction de "::=" et "|" en "→".
Exemple

`Rexp`$\uparrow\ell$	$\to$	`void`	$\ell := \emptyset$
`Rexp`$\uparrow\ell$	$\to$	`epsilon`	$\ell := \{\epsilon\}$
`Rexp`$\uparrow\ell$	$\to$	a	$\ell := \{a\}$
`Rexp`$\uparrow\ell$	$\to$	b	$\ell := \{b\}$
`Rexp`$\uparrow\ell$	$\to$	`u Rexp`$\uparrow\ell_1$ `Rexp`$\uparrow\ell_2$	$\ell := \ell_1\cup\ell_2$
`Rexp`$\uparrow\ell$	$\to$	`dot Rexp`$\uparrow\ell_1$ `Rexp`$\uparrow\ell_2$	$\ell := \ell_1.\ell_2$
`Rexp`$\uparrow\ell$	$\to$	`star Rexp`$\uparrow\ell_1$	$\ell := \ell_1^*$

Ainsi, chaque alternative d'une équation correspond à une *règle*

$$s\,p\,p' \to c \quad s_1 p_1 p'_1 \quad \ldots \quad s_n p_n p'_n \quad \mathcal{A}$$

où p et $(p_i)_{i\in[1,n]}$ sont des listes d'attributs hérités,
où p' et $(p'_i)_{i\in[1,n]}$ sont des listes d'attributs synthétisés,
et où $\mathcal{A}$ est une *action* qui effectue une séquence de *définitions* (notées comme des affectations).

Formalisation de la notion de règle

Une règle

$$s_{n+1}\, p_{n+1}\, p'_{n+1} \to c \quad s_1 p_1 p'_1 \quad \ldots \quad s_n p_n p'_n \quad \mathcal{A}$$

- **définit** une règle de typage $c : s_1 \times \ldots \times s_n \to s_{n+1}$.
- **doit vérifier** pour tout $i \in [1, n+1]$,
  si "$s_i{\downarrow}E_1 \ldots {\downarrow}E_m{\uparrow}E'_1 \ldots {\uparrow}E'_{m'}$"
  alors
  - *p_i est liste de noms* "${\downarrow}x_1 \ldots {\downarrow}x_m$"
    qui représente un élément $(x_1, \ldots, x_m)$ de $E_1 \times \ldots \times E_m$;
  - de même pour p'_i avec ${\uparrow}x'_1 \ldots {\uparrow}x'_{m'}$.
- **doit aussi vérifier** des conditions sur $\mathcal{A}$ (voir diapo suivante)
- **définit alors** une fonction $A_c \in D_{s_1} \times \ldots \times D_{s_n} \to D_{s_{n+1}}$ spécifiée par $\mathcal{A}$ (voir diapo suivante)

Action associée à une règle

Une règle "$s\ p\ p' \to c \quad s_1 p_1 p'_1 \quad \ldots \quad s_n p_n p'_n \quad \mathcal{A}$" définit une fonction $A_c \in D_{s_1} \times \ldots \times D_{s_n} \to D_s$" telle que $A_c(f_1, \ldots, f_n)(p)$ retourne le p' calculé par $\mathcal{A}$ **sous la condition** que :

- $\mathcal{A}$ définisse les noms de $(p_i)_{i\in[1,n]}$ *puis* de p' en fonction de ceux p et $(p'_i)_{i\in[1,n]}$,
- et que pour $i \leq n$, tous les noms de p_i soient définis *avant* toute utilisation d'un nom de p'_i.

Car, implicitement, pour $i \leq n$, les noms de p'_i sont définis à la *première* utilisation d'un de ses noms par "$(x'_1, \ldots, x'_{m'}) := f_i(x_1, \ldots, x_m)$".

NB : cet appel à f_i représente un *appel récursif* sur le i-ème fils du constructeur c.

Exemple d'action associée à une règle

Pour règle

$$s{\downarrow}x{\uparrow}x' \to c \quad s_1{\downarrow}x_1{\uparrow}x'_1 \quad s_2{\downarrow}x_2{\uparrow}x'_2 \qquad \begin{array}{l} x_1 := g_1(x)\ ; \\ x_2 := g_2(x'_1, x)\ ; \\ x' := g(x_1, x'_1, x'_2) \end{array}$$

on obtient $A_c(f_1, f_2) = x \mapsto$ `soit` $x_1 \stackrel{def}{=} g_1(x)$,
`soit` $x'_1 \stackrel{def}{=} f_1(x_1)$,
`soit` $x_2 \stackrel{def}{=} g_2(x'_1, x)$,
`soit` $x'_2 \stackrel{def}{=} f_2(x_2)$,
`retourner` $g(x_1, x'_1, x'_2)$

Même règle avec du "sucre" (noms remplacés par leur def) :

$$s{\downarrow}x{\uparrow}g(g_1(x), x'_1, x'_2) \to c \quad s_1{\downarrow}g_1(x){\uparrow}x'_1 \quad s_2{\downarrow}g_2(x'_1, x){\uparrow}x'_2$$

Chapitre 3 Théorie des syntaxes abstraites

Exemple d'une autre signature Σ_{AST} pour **Prop**

- $\mathcal{S} \stackrel{def}{=} \{\texttt{Bool}, \texttt{Op}, \texttt{Pos}, \texttt{Prop}\}$ et $s_{princ} \stackrel{def}{=} \texttt{Prop}$.
- $\mathcal{C} \stackrel{def}{=} \mathbb{N}\backslash\{0\} \uplus \{\texttt{true}, \texttt{false}, \texttt{and}, \texttt{or}, \texttt{neg}, \texttt{var}, \texttt{cte}, \texttt{op}\}$.
- type défini par :
  - pour $c \in \{\texttt{true}, \texttt{false}\}$, $c : \texttt{Bool}$.
  - pour $c \in \mathbb{N}\backslash\{0\}$, $c : \texttt{Pos}$.
  - pour $c \in \{\texttt{and}, \texttt{or}, \texttt{implies}\}$, $c : \texttt{Op}$.
  - $\texttt{cte} : \texttt{Bool} \to \texttt{Prop}$.
  - $\texttt{var} : \texttt{Pos} \to \texttt{Prop}$.
  - $\texttt{neg} : \texttt{Prop} \to \texttt{Prop}$.
  - $\texttt{op} : \texttt{Prop} \times \texttt{Op} \times \texttt{Prop} \to \texttt{Prop}$.

Exo 3.13† Pouvez-vous construire le terme sur Σ_{AST} associé aux mots suivants en notation préfixe :

1. `& & - & 1 - 2 | - 2 3 | t - 3`
2. `& & - & 1 - 2 | - 2 3`

Introduction à l'analyse syntaxique

Analogie avec le français pour lire "*Ma fille mange une pomme*"

1) Analyse lexicale reconnaît nature de chaque *mot*

déterm.	nom	verbe	déterm.	nom
Ma	*fille*	*mange*	*une*	*pomme*

2) Analyse grammaticale reconnaît structure de la *phrase*

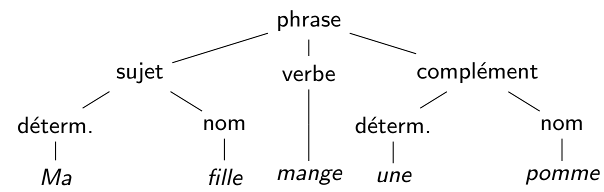

Architecture d'un analyseur syntaxique

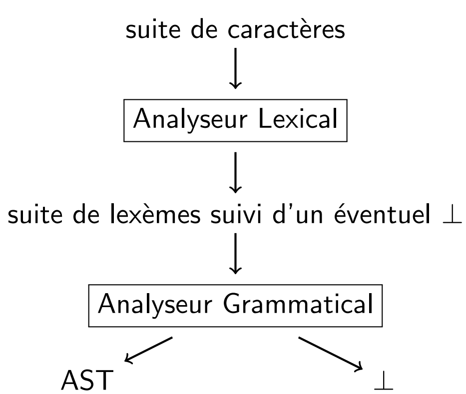

lexème = un mot formé d'une suite de caractères

analyse grammaticale = 1 BNF attribuée produisant AST dont chaque *terminal* nomme un *ensemble de lexèmes* (token) (avec ensemble fini de terminaux).

Exemple de construction d'un AST

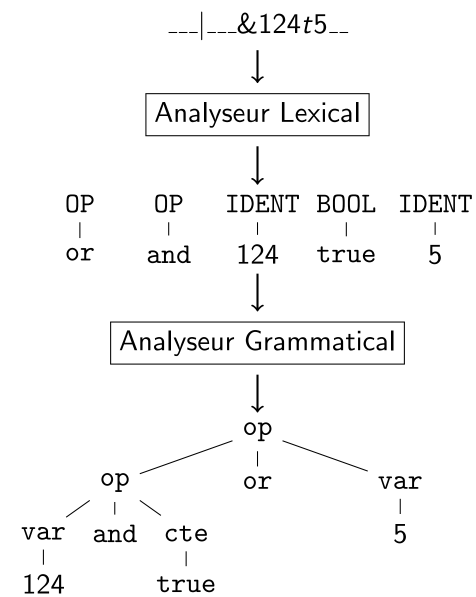

Principes de l'analyse lexicale

- Lecture du prochain lexème **piloté** par analyseur grammatical. (origine du mot "*token*").
  Intérêt : éviter de stocker toute la suite des lexèmes en mémoire !

- Langage d'entrée inclus dans "$(\mathtt{SEP} \cup \mathtt{TOKEN}_1 \cup \ldots \cup \mathtt{TOKEN}_n)^*$"
  où $\mathtt{SEP}$, $\mathtt{TOKEN}_1$, ..., $\mathtt{TOKEN}_n$ sont des langages 2 à 2 disjoints
  avec $\mathtt{SEP}$ un langage régulier de "*séparateurs*"
  et $\mathtt{TOKEN}_1$, ..., $\mathtt{TOKEN}_n$ langages réguliers par "*nature*" de lexèmes.

- *Lecture "gauche/droite" des lexèmes*
  prochain lexème = **+ long préfixe** $\in \mathtt{SEP}^*.(\mathtt{TOKEN}_1 \cup \ldots \cup \mathtt{TOKEN}_n)$
  Exemple sur "124&1", lire "124" comme un seul lexème.

$\Rightarrow$ analyseur lexical = automate fini.

Exemple de lexicographie pour **Prop**

Séparateurs $\mathtt{SEP} \stackrel{def}{=} \{\text{'\_'}\}$

Tokens
Choix d'implémentation lié au fait que dans Σ_{AST}, les sortes autres que **Prop** sont des sortes "feuilles". Il va être commode de faire correspondre ces sortes "feuilles" à un type de lexème !

- $\mathtt{BOOL} \stackrel{def}{=} \{\text{'t'}, \text{'f'}\}$
- $\mathtt{OP} \stackrel{def}{=} \{\text{'\&'}, \text{'|'}, \text{'>'}\}$
- $\mathtt{IDENT} \stackrel{def}{=} \{\text{'1'} \ldots \text{'9'}\}.\{\text{'0'} \ldots \text{'9'}\}^*$
- $\mathtt{NEG} \stackrel{def}{=} \{\text{'-'}\}$

Exo 3.14† Calculer la suite des tokens pour :

1. `123&27|-4_t_6_5_`
2. `___tx2`

L'analyseur grammatical pour **Prop** en notation préfixe

Terminal de la BNF = Token
avec pour non-singleton, valeur du lexème pour attribut

$$\begin{array}{ll} \mathtt{BOOL}\uparrow\{\mathtt{true}, \mathtt{false}\} & \mathtt{IDENT}\uparrow\mathbb{N}\setminus\{0\} \\ \mathtt{NEG} & \mathtt{OP}\uparrow\{\mathtt{and}, \mathtt{or}, \mathtt{implies}\} \end{array}$$

Attribut synthétisé r : mot dans $T_{\Sigma_{AST}}$.

$$\begin{array}{lcll} \mathrm{Parse}\uparrow r & ::= & \mathtt{BOOL}\uparrow b & r := \mathtt{cte}\ b \\ & | & \mathtt{IDENT}\uparrow i & r := \mathtt{var}\ i \\ & | & \mathtt{NEG}\ \ \mathrm{Parse}\uparrow p & r := \mathtt{neg}\ p \\ & | & \mathtt{OP}\uparrow o\ \ \mathrm{Parse}\uparrow p_1\ \ \mathrm{Parse}\uparrow p_2 & r := \mathtt{op}\ p_1\ o\ p_2 \end{array}$$

Exo 3.15† Donner la suite token attribuées de
"&_-_&_123_-_2_|_-_2_3"
puis en construire l'arbre d'analyse Parse avec propagation d'attributs.

L'analyseur lexical comme "itérateur" en C

```c
typedef enum { BOOL, OP, IDENT, NEG, END } Token;

typedef enum { true, false } Bool;
typedef enum { and, or, implies } Op;

typedef union {
   Bool bool;
   Op   op;
   int  ident;
} Attr;

/* retourne END si plus de lexème
   modifie v->bool ssi retourne BOOL
   modifie v->op ssi retourne OP
   modifie v->ident ssi retourne IDENT
*/
Token next(Attr *v);
```

Ici : cadre simplifié avec arrêt immédiat en cas d'erreur.
En général : un token spécial $\mathtt{ERR}$ pour laisser analyseur grammatical gérer erreur.

Méthode gale de construction de l'implémentation

Principes

- langage "$\mathtt{SEP}^*.(\mathtt{TOKEN}_1 \cup \ldots \cup \mathtt{TOKEN}_n)$" régulier donc reconnaissable par automate fini déterministe complet (avec état erreur) A.
- Calcul du prochain lexème :
  1. lecture successive des caractères jusqu'à état erreur dans A (ou fin du texte).
  2. si *état final* recontré, le lexème correspond au dernier état final.
  3. sinon, erreur (pas de lexème).
- Utilisation d'un "*buffer de pré-vision*" (look-ahead) mémorisant caractères lus entre état final et état erreur (préfixe du prochain lexème).

NB Très souvent un buffer de 1 caractère suffit !
Contre-exemple : < et <=> lexèmes, mais pas <=

Autres tâches souvent dédiées à l'analyseur lexical

Pré-processing (limité à des calculs sur langages réguliers)

- suppression des commentaires (considérés comme séparateurs).
- mécanisme de `#include` à la C.

Dictionnaire des identificateurs & mots-clés

- codage efficace des identificateurs dans AST (via "pointeur" partagé pour identificateurs de même nom).
- simplification de l'automate pour discrimination *mot-clés*/*identificateurs*.

SdD de localisation dans le source (pour messages d'erreurs).

L'analyseur grammatical en C (avec $\mathtt{Prop} \stackrel{def}{=} T_{\Sigma_{AST}}$)

Principe fonction `parse_rec` basée sur lemme du préfixe unique.

```
static Prop parse_rec() {
    Attr v;
    Token current=next(&v);
    switch (current) {
    case BOOL: return cte(v.bool);
    case IDENT: return var(v.ident);
    case NEG:
         Prop p = parse_rec();
         return neg(p);
    case OP:
         Prop p1 = parse_rec();
         Prop p2 = parse_rec();
         return op(p1,v.op,p2);
    default: // cas du END (ou lexeme inconnu)
         error_unexpected(current, v);
    }
}
```

NB ds pg principal, après appel à "`parse_rec()`", vérifier "`next()==END`" !

Notion d'arbre d'analyse (parse tree)

- On a deux notions d'arbres :
  1. ceux de $T_{\Sigma_{AST}}$ = AST = arbres abstraits
  2. et les *arbres d'analyse* (ou *parse trees* en anglais) associées à la BNF de Parse.
- Les arbres d'analyse de Parse ne sont pas explicitement construits par l'analyseur `parse_rec`. En fait, ils correspondent aux *arbres des appels récursifs* de cette fonction.

Exo 3.16† dessiner l'arbre des appels récursifs de `parse_rec` sur le mot "`& - & 123 - 2 | - 2 3`".