

Chapitre 5 Théorie des grammaires et du parsing

5.1 Grammaires hors-contextes et réécritures sur les mots

5.2 Analyse syntaxique

Panorama de la suite du cours

Grammaires hors-contextes (GHC) :

- ▶ équivalent à la notion de langage algébrique.
- ▶ donne un procédé de calcul, par *réécriture*, plus “souple” que calcul de $\bigcup_{i \in \mathbb{N}} F^i(\emptyset)$.
NB : algos efficaces pour décider si $w \in L$.
- ▶ analyse LL(1) des GHC : algo efficace d'analyse syntaxique qui généralise celui vu sur la notation préfixe.

Objectif du cours GHC LL(1) attribuées = méta-language pour générer automatiquement des interpréteurs.

Idée des GHC

On voit une BNF

$$\begin{cases} S ::= X S b \mid \epsilon \\ X ::= a \mid a a \end{cases}$$

comme un **système** de *règles de réécritures* sur $(\mathcal{V}_N \cup \mathcal{V}_T)^*$

$$\begin{cases} S \rightarrow X S b \\ S \rightarrow \epsilon \\ X \rightarrow a \\ X \rightarrow a a \end{cases}$$

Idée d'une réécriture

Une réécriture de règle $l \rightarrow r$ dans un mot w
= remplacer 1 occurrence de l par r dans w .

Exemple sur $X X S b b$ avec **règle** $X \rightarrow a a$

Deux possibilités

soit $a a X S b b$

soit $X a a S b b$

Définition de réécritures (Thue 1914)

Un **système de réécriture de mots** R est un couple $(\mathcal{V}, \mathcal{R})$ tq :

- ▶ \mathcal{V} ensemble *fini* de symboles, appelé **alphabet** (ou *vocabulaire*) ;
- ▶ et, \mathcal{R} sous-ensemble *fini* de $\mathcal{V}^* \times \mathcal{V}^*$.
Un couple $(l, r) \in \mathcal{R}$ s'appelle une **règle de réécriture** (ou *production*) et se note plutôt " $l \rightarrow r$ ".

On note $w \Rightarrow_R w'$ ssi il existe u, v de \mathcal{V}^* et $l \rightarrow r \in \mathcal{R}$ tels que $w = u l v$ et $w' = u r v$.

On note $w \Rightarrow_R^* w'$ (c-à-d. " w se réécrit en w' " ou " w' **dérive de** w ") ssi il existe une suite $(u_i)_{i \in 0..n}$ telle que $u_0 = w$ et $u_n = w'$ et pour tout i de $1..n$, $u_{i-1} \Rightarrow_R u_i$.

Réécriture en dérivation gauche

On choisit toujours une règle qui s'applique "**le plus à gauche**".

Exemple sur $X X S b b$ avec **système** précédent

Deux possibilités

- soit $a X S b b$ (pour règle $X \rightarrow a$)
- soit $a a X S b b$ (pour règle $X \rightarrow aa$)

Définitions des grammaires génératives (Chomsky 1956)

Une grammaire G est un 4-uplet $(\mathcal{V}_T, \mathcal{V}_N, S, \mathcal{R})$ avec :

- ▶ \mathcal{V}_T alphabet *fini* des **terminaux** (alphabet du langage qu'on veut engendrer à l'aide de G).
- ▶ \mathcal{V}_N alphabet *fini* des **non-terminaux** (symboles "auxiliaires" utilisés dans étapes intermédiaires de réécriture).
- ▶ $S \in \mathcal{V}_N$ est l'**axiome** ("*start symbol*" en anglais).
- ▶ \mathcal{R} un ensemble de règles tq $(\mathcal{V}, \mathcal{R})$ système de réécriture avec $\mathcal{V} \stackrel{\text{def}}{=} \mathcal{V}_T \uplus \mathcal{V}_N$. On appelle aussi G ce système de réécriture.

Le langage L_G **engendré** (ou *reconnu*) par G est

$$L_G \stackrel{\text{def}}{=} \{w \in \mathcal{V}_T^* / S \Rightarrow_G^* w\}$$

Grammaires hors-contextes

Une grammaire est dite **hors-contexte** ssi toutes les règles sont de la forme :

$$A \rightarrow \alpha \text{ avec } A \text{ dans } \mathcal{V}_N \text{ et } \alpha \in \mathcal{V}^*$$

Thm La GHC associée à une BNF engendre le langage de la BNF.

Classification de Chomsky (1956) / Knuth[†] (1965)

Langages	Grammaires génératives	Automates reconnaisseurs	Exemple caractéristique
quelconques	aucune	aucun	ens. des fonctions Python à 1 paramètre qui terminent sur une entrée A et qui bouclent sur une entrée B (A, B fixés).
rékursivement énumérables	type 0	machines de Turing (semi-algorithme !)	ens. des pg Python sans entrée qui terminent
contextuels	type 1	automates linéairement bornés	$\{ a^n b^n c^n \mid n \in \mathbb{N} \}$
hors-contextes (ou algébriques)	type 2	automates à piles	ens. des palindromes $\{ w \in \{a, b\}^* \mid w = \bar{w} \}$
hors-contextes déterministes	$LR(k)^\dagger$	automates à piles déterministes	$\{ a^n b^n \mid n \in \mathbb{N} \}$
réguliers	type 3	automates finis	$a.(b + c)^*$

horizontalement équivalence entre classes de langages/grammaires/automates

verticalement (de bas en haut) inclusion *stricte* cf. exemple caractéristique

Plan de la section 5.2

5.2 Analyse syntaxique

5.2.1 Théorie de l'analyse syntaxique LL(1)

5.2.2 Implémentation de l'analyseur LL(1)

5.2.3 Constructions de (E)BNF LL(1) en pratique

5.2.4 Mise en Perspectives & Conclusions

Chapitre 5 Théorie des grammaires et du parsing

5.1 Grammaires hors-contextes et réécritures sur les mots

5.2 Analyse syntaxique

Introduction

“LL(1)” pour “Left-to-right reading, Leftmost derivation, 1 lookahead”.

↪ Analyse syntaxique en dérivation-gauche limitée aux GHC où on a *stratégie complète et déterministe* en sélectionnant la *bonne règle* uniquement à partir du *premier* caractère du w en entrée.

NB De telles GHC sont dites LL(1).

Intérêts

- ▶ grammaires LL(1) non-ambiguës par construction.
- ▶ décidabilité de la vérif qu'une GHC est LL(1).
- ▶ la plupart des constructions usuelles des langages informatiques peuvent s'exprimer via grammaires LL(1).
- ▶ parsing efficace (sans backtracking) et facile à implémenter
⇒ généralise automate fini déterministe + parsing en notation préfixe

Difficulté

Indécidable de trouver une forme LL(1) pour une GHC donnée.

Intuition de l'analyse LL(1) sur des exemples (1/2)

Exo On considère la BNF d'équation $S ::= b \mid a S a S$.

1) Compléter la procédure de parsing récursif `parse_S` ci-dessous :

```
typedef enum { a, b, END } token;
token next(); // analyseur lexical

void parse_S() { ... }
void parse() { // procédure principale du parsing
    parse_S(); if (next() != END) { printf("ERROR"); exit(1); }
}
```

2) Adapter ensuite votre code pour la version alternative

```
token current; // var. globale de pré-vision (look-ahead)

void parse_token(token expected) { // consommer "current"
    if (current != expected) { printf("ERROR"); exit(1); }
    if (current != END) { current = next(); }
}

void parse_S() { ... }
void parse() { // procédure principale du parsing
    current = next(); // init. "current" (sur 1er token)
    parse_S(); parse_token(END);
}
```

Réduction de GHC

Avant de considérer si G est LL(1), il faut d'abord la *réduire* :

- ▶ supprimer de G les non-terminaux A *improductifs*, c-à-d tq il n'existe pas $w \in \mathcal{V}_T^*$ tq $A \Rightarrow^* w$.
- ▶ supprimer de G les non-terminaux A *inaccessibles*, c-à-d tq il n'existe pas α_1 et α_2 de \mathcal{V}^* tq $S \Rightarrow^+ \alpha_1 A \alpha_2$.

NB : supprimer A de $G \rightsquigarrow$ supprimer ttes les règles où A figure.

Exo 5.1 Montrer que réduire G ne change pas L_G .

Thm les propriétés "être improductif" et "être inaccessible" sur une GHC qq sont décidables.

(Par calculs de point-fixe similaires à ceux du chapitre 2).

Corollaire il y a un algo pour réduire une GHC qq.

Intuition de l'analyse LL(1) sur des exemples (2/2)

Exo Adapter la démarche précédente pour cette BNF équivalente à la précédente

$$S ::= b \mid X X \quad X ::= a S$$

avec deux procédures mutuellement récursives :

```
void parse_S() { ... }
void parse_X() { ... }
```

Exo Essayer d'adapter la démarche précédente pour chacune des BNF du langage $\{ a^n b^n a \mid n \in \mathbb{N} \}$:

1. $S ::= a X$
 $X ::= A b a \mid \epsilon$
 $A ::= a A b \mid \epsilon$
2. $S ::= A a$
 $A ::= a A b \mid \epsilon$

NB : on pourra simuler l'algorithme dans la reconnaissance de "a" puis "a b a", puis "a³ b³ a".

Définition des grammaires LL(1) (Lewis/Stearns 1968)

Soit G une GHC **réduite**. Soit $\$ \notin \mathcal{V}$ (sentinelle de fin d'entrée).

On pose $\mathcal{V}_{T\cup\$} \stackrel{\text{def}}{=} \mathcal{V}_T \cup \{\$ \}$.

Définition du directeur $\text{Dir}(\pi)$ d'une règle $\pi = A \rightarrow \alpha$.

$\text{Dir}(\pi)$ est défini comme l'ensemble des $a \in \mathcal{V}_{T\cup\$}$ pour lesquels il existe $w_1 \in \mathcal{V}_T^*$, w_2 et w_3 de $\mathcal{V}_{T\cup\* tq

$$S \$ \Rightarrow^* w_1 A w_2 \text{ et } \alpha w_2 \Rightarrow^* a w_3$$

NB 1 : dans def ci-dessus, on peut avoir $\alpha \Rightarrow^* \epsilon$.

NB 2 : G réduite implique $\text{Dir}(\pi) \neq \emptyset$

Intuition dans parsing récursif, une règle π de forme $A \rightarrow \alpha$ ne peut dériver "a w" que si $a \in \text{Dir}(\pi)$.

Déf G est dite LL(1) ssi pour ttes règles $A \rightarrow \alpha$ et $A \rightarrow \beta$,

$$\alpha \neq \beta \text{ implique } \text{Dir}(A \rightarrow \alpha) \cap \text{Dir}(A \rightarrow \beta) = \emptyset$$

Exo 5.2 Montrer que G LL(1) implique G non ambiguë.

Calcul du directeur des règles

On décompose le calcul en :

$$\text{Dir}(A \rightarrow \alpha) = \text{Prem}(\alpha) \cup \mathcal{E}(\alpha).\text{Suiv}(A)$$

où

1. " $\mathcal{E}(\alpha).X$ " est une notation pour "si $\alpha \Rightarrow^* \epsilon$ alors X sinon \emptyset "
2. $\text{Prem}(\alpha) = \{a \in \mathcal{V}_T \mid \text{il existe } w \in \mathcal{V}_T^* \text{ tq } \alpha \Rightarrow^* a w\}$.
3. $\text{Suiv}(A)$ est l'ensemble des $a \in \mathcal{V}_{T \cup \$}$ tels qu'il existe $w_1 \in \mathcal{V}_T^*$ et $w_2 \in \mathcal{V}_{T \cup \* avec $S \$ \Rightarrow^* w_1 A a w_2$.

Plan de la suite : calcul de \mathcal{E} , Prem et Suiv par **commutation** de +petit point-fixe.

Calcul de \mathcal{E} sur un exemple

Exo 5.3[†] Appliquer cette méthode sur la BNF

$S ::= X a \mid S X$
 $X ::= b S \mid \epsilon$

...

Exo 5.4[†] Idem en remplaçant l'équation de S ci-dessus par

$S ::= X a \mid X$

...

Décider $\epsilon \in L$ avec L langage HC (i.e. algébrique)

On se ramène au calcul de $\mathcal{E}(L) \stackrel{\text{def}}{=} L \cap \{\epsilon\}$.

On définit $g(X_1, \dots, X_n) \stackrel{\text{def}}{=} (\mathcal{E}(X_1), \dots, \mathcal{E}(X_n))$

pour appliquer le **lemme de commutation** (cf. chap 2).

Système à résoudre obtenu en transformant chaque équation

" $X_k ::= e_k$ " de la BNF de L en équation " $\mathcal{E}(X_k) = \mathcal{E}(e_k)$ "

où " $\mathcal{E}(X_k)$ " est vue comme une variable

et " $\mathcal{E}(e_k)$ " calculé récursivement sur syntaxe de e_k pour s'exprimer en fonction de $\mathcal{E}(X_1), \dots, \mathcal{E}(X_n)$:

- ▶ $\mathcal{E}(\epsilon) = \{\epsilon\}$ et pour tout terminal a , $\mathcal{E}(a) = \emptyset$
- ▶ $\mathcal{E}(\alpha.\beta) = \mathcal{E}(\alpha) \cap \mathcal{E}(\beta)$
- ▶ $\mathcal{E}(\alpha \mid \beta) = \mathcal{E}(\alpha) \cup \mathcal{E}(\beta)$

Calcul du +ptit pt fixe (sur $E = [1, n] \times \{\epsilon\}$)

ou par éliminations successives en exploitant la propriété suivante :

la +petite solution de $X = (X \cap \alpha) \cup \beta$ vérifie aussi $X = \beta$

Calcul de Prem

Même méthode que \mathcal{E} en ramenant le calcul à

$\text{Prem}(X) = \{a \in \mathcal{V}_T \mid \exists w \in \mathcal{V}_T^*, a w \in X\}$.

Système d'équations pour lemme de commutation

Transformation de chaque équation " $X_k ::= e_k$ " de la BNF

en équation " $\text{Prem}(X_k) = \text{Prem}(e_k)$ " où " $\text{Prem}(e_k)$ " calculé par récursion structurelle sur syntaxe de e_k :

- ▶ $\text{Prem}(\epsilon) = \emptyset$
- ▶ Pour tout $a \in \mathcal{V}_T$, $\text{Prem}(a) = \{a\}$
- ▶ $\text{Prem}(\alpha.\beta) = \text{Prem}(\alpha) \cup \mathcal{E}(\alpha).\text{Prem}(\beta)$
- ▶ $\text{Prem}(\alpha \mid \beta) = \text{Prem}(\alpha) \cup \text{Prem}(\beta)$

Calcul de +ptit point-fixe sur $E = [1, |\mathcal{V}_N|] \times \mathcal{V}_T$.

Calcul de Prem

Même méthode que \mathcal{E} en ramenant le calcul à

$\text{Prem}(X) = \{a \in \mathcal{V}_T \mid \exists w \in \mathcal{V}_T^*, a w \in X\}$.

Système d'équations pour lemme de commutation

Transformation de chaque équation " $X_k ::= e_k$ " de la BNF

en équation " $\text{Prem}(X_k) = \text{Prem}(e_k)$ " où " $\text{Prem}(e_k)$ " calculé par récursion structurelle sur syntaxe de e_k :

- ▶ $\text{Prem}(\epsilon) = \emptyset$
- ▶ Pour tout $a \in \mathcal{V}_T$, $\text{Prem}(a) = \{a\}$
- ▶ $\text{Prem}(\alpha.\beta) = \text{Prem}(\alpha) \cup \mathcal{E}(\alpha).\text{Prem}(\beta)$
- ▶ $\text{Prem}(\alpha \mid \beta) = \text{Prem}(\alpha) \cup \text{Prem}(\beta)$

Calcul de +ptit point-fixe sur $E = [1, |\mathcal{V}_N|] \times \mathcal{V}_T$.

Calcul de Suiv

Système d'équations variables $(\text{Suiv}(X))_{X \in \mathcal{V}_N}$ d'équation

$$\text{Suiv}(X) = \begin{array}{l} \text{si } X \text{ axiome alors } \{\$ \} \text{ sinon } \emptyset \\ \cup \\ \bigcup_{Y \rightarrow \alpha.X.\beta \in \mathcal{R}} \text{Prem}(\beta) \cup \mathcal{E}(\beta).\text{Suiv}(Y) \end{array}$$

NB dans énumération ci-dessus des règles de forme " $Y \rightarrow \alpha.X.\beta$ " une même règle de \mathcal{R} est utilisée autant de fois que X apparaît dans le membre droit. Par ex, la règle $B \rightarrow a.A.b.A$ compte avec " $\alpha = a, \beta = b.A$ " puis avec " $\alpha = a.A.b, \beta = \epsilon$ ".

Calcul du +petit pt fixe sur $E = [1, |\mathcal{V}_N|] \times \mathcal{V}_{T \cup \$}$.

Plan de la section 5.2

5.2 Analyse syntaxique

5.2.1 Théorie de l'analyse syntaxique LL(1)

5.2.2 Implémentation de l'analyseur LL(1)

5.2.3 Constructions de (E)BNF LL(1) en pratique

5.2.4 Mise en Perspectives & Conclusions

Mini-Exemple

Exo 5.5[†] Pour chacune des 4 grammaires ci-dessous du langage $\{a^n b^m \mid 0 \leq n \leq m\}$:

1. $S \rightarrow a S B \mid \epsilon \mid B$
 $B \rightarrow b B \mid b$
2. $S \rightarrow a S b B \mid B$
 $B \rightarrow b B \mid \epsilon$
3. $S \rightarrow a S b \mid B$
 $B \rightarrow b B \mid \epsilon$
4. $S \rightarrow A B$
 $A \rightarrow a A b \mid \epsilon$
 $B \rightarrow b B \mid \epsilon$

Calculer le directeur de chacune des règles. Quelles grammaires sont LL(1) ?

Cadre de la présentation

Cadre simplifié :

- arrêt du programme à la première erreur ;
- token sans attribut (cf. généralisation en TP).

Analyseur lexical

```
typedef enum { ... } token;
token next();
```

Interface avec l'analyseur lexical

```
/* variable globale de look-ahead */
token current;

/* vérifie "current==expected" puis fait "current=next();" */
void parse_token(token expected);
```

Principe de l'analyseur récursif

Analyseur donné par procédures *mutuellement récursives*.

Intuition : arbre d'analyse reconnu = arbre des appels récursifs.

Ainsi, pour tt non-terminal de profil $X \downarrow H_1 \dots \downarrow H_n \uparrow S_1 \dots \uparrow S_m$,

```
void parse_X(H1 h1, ..., Hn hn, S1 *s1, ..., Sm *sm);
```

reconnaît le *+long préfixe* de l'entrée qui correspond à X et affecte attributs comme spécifié dans équation de $X \downarrow h_1 \dots \downarrow h_n \uparrow s_1 \dots \uparrow s_m$.

Attention :

- ▶ `parse_X` lit le 1er token dans `current`.
En sortie, `current` sur le 1er token qui suit le préfixe reconnu.
- ▶ Échec de `parse_X` \Rightarrow soit pas de préfixe de X dans l'entrée, soit *+long préfixe* pas suivi d'un token de `Suiv(X)`.

Message d'erreur en analyse LL(1)

Sur cette BNF

$$\begin{array}{l} \{a\} \quad A \rightarrow a A b \\ \{b, \$\} \quad | \quad \epsilon \end{array}$$

3 choix d'implémen. qui changent juste messages d'erreur

```
void parse_A(){
    switch(current){
        case b: case eof:
            break;
        default:
            parse_token(a);
            parse_A();
            parse_token(b);
            break;
    }
}
```

```
void parse_A(){
    switch(current){
        case a:
            parse_token(a);
            parse_A();
            parse_token(b);
            break;
        default:
            break;
    }
}
```

```
void parse_A(){
    switch(current){
        case a:
            parse_token(a);
            parse_A();
            parse_token(b);
            break;
        case b: case eof:
            break;
        default:
            unxpct("a b $");
    }
}
```

Exemple d'erreur

aac
↑ attend a

aac
↑ attend b

aac
↑ attend a b \$

Codage "automatique" des équations sur un exemple

Équation annotée avec **directeurs**

$$\begin{array}{l} \{a_1, \dots, a_n\} \quad X \downarrow h \uparrow s \rightarrow A \uparrow s \ c \\ \{b_1, \dots, b_m\} \quad | \quad C \downarrow h \uparrow s_0 \ e \ D \downarrow f(h, s_0) \uparrow s_1 \quad s := g(s_0, s_1) \end{array}$$

traduite en

```
void parse_X(H h, S *s){
    S0 s0; S1 s1;
    switch (current) {
        case a1: ... : case an:
            parse_A(s);
            parse_token(c); break;
        case b1: ... : case bm:
            parse_C(h, &s0);
            parse_token(e);
            parse_D(f(h, s0), &s1);
            *s = g(s0, s1); break;
        default: unexpected_token("X");
    }
}
```

Incompatible avec dép droite/gauche ds éval des attributs!

Restriction correspondant aux "*grammaires L-attribuées*"

Plan de la section 5.2

5.2 Analyse syntaxique

5.2.1 Théorie de l'analyse syntaxique LL(1)

5.2.2 Implémentation de l'analyseur LL(1)

5.2.3 Constructions de (E)BNF LL(1) en pratique

5.2.4 Mise en Perspectives & Conclusions

Tout langage régulier L est LL(1)

BNF LL(1) de L = système d'équations (linéaires à droite) de l'automate déterministe minimal de L moins l'éventuel état puit.

Exo 5.6 Faire la preuve que la BNF est bien LL(1).

...

EBNF LL(1) L-attribuée pour associativité à droite

Équation non LL(1) suivante (codant '**' associatif à droite)

$$\begin{aligned} \text{exp}_1 \uparrow r &::= \text{exp}_0 \uparrow r_1 \text{ '**' } \text{exp}_1 \uparrow r_2 & r &:= r_1^{r_2} \\ &| \text{exp}_0 \uparrow r \end{aligned}$$

après factorisation de exp_0 , équivaut à :

$$\text{exp}_1 \uparrow r ::= \text{exp}_0 \uparrow r_1 (\epsilon \{r := r_1\} \mid \text{'**'} \text{exp}_1 \uparrow r_2 \{r := r_1^{r_2}\})$$

Exo 5.7[†] Montrer que l'équation est LL(1) ssi '**' $\notin \text{Suiv}(\text{exp}_1)$

Si LL(1), équation EBNF qui s'implémente en :

```
void parse_exp1(int *r){
    int r1, r2;
    parse_exp0(&r1);
    if (current=='**') {
        parse_token('**');
        parse_exp1(&r2);
        *r=pow(r1,r2);
    } else { *r=r1; }
}
```

Les calculs de directeurs LL(1) s'étendent aux EBNF

Définition EBNF = BNF avec expressions régulières en membre droits d'équations

⇒ **expressif & efficace** pour engendrer analyseurs LL (cf. méta-interpréteur ANTLR)

Exemple 1 $X ::= \alpha_1.(\alpha_2)^*.\alpha_3$

se réécrit (pour le calcul de directeur) en

$$X ::= \alpha_1.X'.\alpha_3 \quad X' ::= \alpha_2.X' \mid \epsilon$$

Exemple 2 $X ::= \alpha_1.(\alpha_2 \mid \alpha_3).\alpha_4$

se réécrit (pour le calcul de directeur) en

$$X ::= \alpha_1.X'.\alpha_4 \quad X' ::= \alpha_2 \mid \alpha_3$$

EBNF LL(1) L-attribuée pour associativité à gauche

Équation non LL(1) suivante (codant '-' associatif à gauche)

$$\begin{aligned} \text{exp}_1 \uparrow r &::= \text{exp}_1 \uparrow r_1 \text{ '-' } \text{exp}_0 \uparrow r_2 & r &:= r_1 - r_2 \\ &| \text{exp}_0 \uparrow r \end{aligned}$$

par "symétrique" du lemme d'Arden, équivaut à :

$$\text{exp}_1 \uparrow r ::= \text{exp}_0 \uparrow r_1 \{r := r_1\} (\text{'-'} \text{exp}_0 \uparrow r_2 \{r := r - r_2\})^*$$

Exo 5.8[†] Montrer que l'équation est LL(1) ssi '-' $\notin \text{Suiv}(\text{exp}_1)$

Si LL(1), équation EBNF qui s'implémente en :

```
void parse_exp1(int *r){
    int r1, r2;
    parse_exp0(&r1);
    *r=r1;
    Loop: if (current=='-') {
        parse_token('-');
        parse_exp0(&r2);
        *r -= r2;
        goto Loop;
    }
}
```


Plan de la section 5.2

5.2 Analyse syntaxique

- 5.2.1 Théorie de l'analyse syntaxique LL(1)
- 5.2.2 Implémentation de l'analyseur LL(1)
- 5.2.3 Constructions de (E)BNF LL(1) en pratique
- 5.2.4 Mise en Perspectives & Conclusions

Mini état de l'art sur les méta-compilateurs

- Analyse LR(1) (ou sa variante LALR(1)) est prédominante depuis longtemps (avec Yacc). LR(k) pour $k > 1$ est actuellement considéré comme impraticable.
NB : toute grammaire LL(k) est LR(k).
- Analyse LL(*) apparue en 2005 avec AntLR (AntLR v3).
- Il existe des *langages* qui ne peuvent pas être reconnus en LR(1) mais qui peuvent l'être en LL(*) et réciproquement ! Par ailleurs, le langage des palindromes ne peut être reconnu ni en LL(*), ni en LR(k).

Au-delà de l'analyse LL(1)

Intérêt des grammaires LL(1) algo d'analyse syntaxique simple et efficace.

Généralisable en LL(n) avec n symboles de pré-vision, voire en LL(*) avec buffer de pré-vision = langage régulier cf. méta-compilateur AntLR3 pour grammaires LL(*).

Grammaires LR souvent utilisées pour langages de programmation classiques. Algo d'analyse syntaxique plus complexe. Nécessite méta-compilateur (e.g. Yacc).

Exemple de langage LR(1) qui n'est pas LL(*)

Le langage $\{a^m b^n \mid m \geq n\}$ est reconnu par une grammaire LR(1) :

$$\begin{aligned} S &::= a S \mid X \\ X &::= a X b \mid \epsilon \end{aligned}$$

Mais il n'existe aucune grammaire LL(*) qui reconnait ce langage.
NB : résultat non trivial, car par contre, pour tout p , il existe une grammaire LL(1) qui reconnait $\{a^m b^n \mid n + p \geq m \geq n\}$.

Exemple de langage LL(2) qui n'est pas LR(1)

Le langage $\{a^n(ab)^n \mid n \in \mathbb{N}\}$ est reconnu par une grammaire LL(2) :

$$S ::= a S a b \mid \epsilon$$

mais il n'existe aucune grammaire LR(1) (et donc aucune LL(1)) qui reconnaît ce langage.

NB : grammaire ci-dessus LL(2), donc aussi LR(2) et LL(*).