



# *Langages formels et calculabilité*

## *MIASHS L2*

(d'après le cours de Julie Dugdale)

Jérôme GENSEL – [Jerome.Gensel@univ-grenoble-alpes.fr](mailto:Jerome.Gensel@univ-grenoble-alpes.fr)

Université Grenoble Alpes France

UFR SHS – Laboratoire d'Informatique de Grenoble



# Quelques informations pratiques...

# Organisation du cours :

## Langages Formels et Calculabilité

- 10h30 de CM → 7 séances de 1h30
  - Lundi de 8h30 à 10h
- 19h30 de TD : 3 groupes de TD → 13 séances de 1h30
  - Le mardi, en général
- Si vous avez besoin de me contacter :
  - Bureau C14 à l'UFR
  - [Jerome.Gensel@univ-grenoble-alpes.fr](mailto:Jerome.Gensel@univ-grenoble-alpes.fr)
- Ce cours et les TD associés seront déposés sur la plateforme Moodle
  - L2 - S4 - Langages formels et calculabilité

# Examen & Contrôle Continu

La note finale est composée de :

- 50% de la note de l'Examen
- 50% de la note de Contrôle Continu  
→ un test pendant un CM au mois de mars...

# Plan du cours

- Chapitre 1 : mots, langages et expressions régulières
- Chapitre 2 : automates à états finis
- Chapitre 3 : automates à états finis non-déterministes
- Chapitre 4 : grammaires (2 cours)
- Chapitre 5 : automates à piles
- Chapitre 6 : machine de Turing



# Mots, langages et expressions régulières





# Sommaire

- Introduction au cours
- Qu'est-ce qu'un langage ?
- Alphabet, mots
- Propriétés des mots
- Langages
- L'étoile de Kleene
- Langages réguliers
- Expressions régulières

# Introduction au cours

- Cours d'introduction à la **théorie du calcul**
- Une vue des **fondements** de l'informatique théorique
- Couvre des sujets tels que :  
*les langages formels, les grammaires (formelles), les automates à états fini, la détermination des automates, les automates à piles, les machines de Turing, etc.*



# Introduction au cours

- C'est un cours théorique, mais ces sujets sont étroitement associés à des **sujets pratiques**
- Exemples:
  - La théorie des automates et les langages formels sont utilisés pour la **construction de compilateurs, définition de langages de programmation**
  - La définition de grammaires formelles est nécessaire pour la **génération et la validation automatique de phrases** (par exemple, pour la **communication entre machines, pour vérifier la syntaxe des programmes**, etc.)
  - Calculabilité : utilisé pour **évaluer la possibilité d'écrire un programme** pour résoudre un problème donné (peut être que le problème ne peut pas être résolu par un ordinateur)

# Introduction au cours (d'après C. Solnon)

- Les langages servent à communiquer, à échanger des informations, des idées.
- Ils doivent aussi permettre aux humains de communiquer avec les ordinateurs, ces machines binaires ultra-rapides...
- Le langage commun entre les êtres humains est appelé *langage naturel*.
- Les **phrases** ou **expressions** de ce langage peuvent être **informelles**, **ambiguës**.
  - Elles nécessitent parfois une *interprétation* de notre cerveau en fonction du *contexte* pour en déterminer le sens.
- Par opposition, les langages créés par l'homme pour communiquer avec les **ordinateurs** sont des **langages artificiels**.
- Ils doivent être **formalisés** et **non ambigus** pour pouvoir être interprétés par une **machine**.

# Introduction au cours (d'après C. Solnon)

- Basiquement, l'ordinateur ne comprend qu'un seul langage : son **langage machine**.
- Pour communiquer avec l'ordinateur à l'aide de langages plus évolués, il faut utiliser un *interprète* (qui traduit interactivement les instructions entrées au clavier), ou bien un **compilateur** (qui traduit tout un programme).
- L'interprétation ou la compilation d'un texte se décompose généralement en 3 étapes :
  1. **L'analyse lexicale** qui permet de décomposer le texte en entités élémentaires appelées **lexèmes** (*tokens* en anglais).
  2. **L'analyse syntaxique** qui permet de reconnaître des combinaisons de lexèmes formant des **entités syntaxiques**.
  3. **L'analyse sémantique** qui permet de générer le code objet directement compréhensible par la machine (ou bien un code intermédiaire qui devra être de nouveau traduit dans un code machine).

# Introduction au cours (d'après C. Solnon)

- Considérons par exemple, le (morceau de) texte C suivant :  $cpt = i + 3.14;$ 
  1. L'analyse lexicale permet d'identifier les lexèmes suivants : un **IDENTIFICATEUR** de valeur  $cpt$  , un **OPERATEUR** de valeur  $=$  , un **IDENTIFICATEUR** de valeur  $i$  , un **OPERATEUR** de valeur  $+$  , un **REEL** de valeur  $3.14$  et un **POINT VIRGULE** .
  2. L'analyse syntaxique permet de reconnaître que cette combinaison de lexèmes forme une instruction (expression) d'un langage de programmation (ici, le langage C) syntaxiquement correcte, et qu'il s'agit d'une affectation entre la variable d'identificateur  $cpt$  et l'expression arithmétique résultant de l'addition de la variable d'identificateur  $i$  avec le réel  $3.14$ .
  3. Enfin, l'analyse sémantique vérifie le bon typage des variables  $cpt$  et  $i$  , puis génère le code objet correspondant à cette instruction.
- Les phases d'analyse lexicale et syntaxique constituent en fait un même problème (à deux niveaux différents) : il s'agit de **reconnaître une combinaison valide d'entités** : une combinaison de caractères formant des lexèmes pour l'analyse lexicale, et une combinaison de lexèmes formant des programmes pour l'analyse syntaxique.
- La théorie des langages permet de résoudre ce type de problème.



# Qu'est-ce qu'un langage ?

- Clarifier les termes de langage formel et langage naturel
- On peut différencier ces deux termes par la question :
  - Lequel est arrivé le premier, le langage ou ses règles grammaticales ?

# Qu'est-ce qu'un langage ?

Langage naturel (par exemple, le français, l'anglais, l'espagnol, *etc.*) **évolue** avec le temps

- Sans considération pour les règles grammaticales formelles
- Les règles se sont développées **plus tard** pour **expliquer** la structure du langage, plutôt que pour la déterminer.



# Qu'est-ce qu'un langage ?

- Au contraire, les langages formels (tels que ceux étudiés dans ce cours) sont **définis par** et se **conforment à** des règles préétablies
- Exemples :  
*les langages de programmation, les langages mathématiques (algèbre, logique propositionnelle, etc.)*

# Qu'est-ce qu'un langage ?

- Nous nous situons ici à un niveau très rudimentaire de l'étude des «langages»
- Pour nous, un **langage** est simplement un **ensemble de *suites de lettres***...  
on dit aussi : **mots**,  
on dit aussi : **chaînes de caractères**

# Qu'est-ce qu'un langage ?

- L'ensemble des phrases grammaticalement correctes du *français* standard est un langage
- L'ensemble des programmes syntactiquement corrects écrits en JAVA est un langage
- $\{0, 01, 10, 00, 11, 000, 001, 010, 100, 011, 101, 110, 111\}$  est un langage
- $\{la, lala, lalala, lalalala, lalalalala, \dots, lalalala\dots la, \dots\}$  est un langage
- $\{T, \perp T, \perp \perp T, \perp \perp \perp T, \dots\}$  est un langage

# Alphabet, mots

- **Alphabet** : tout ensemble fini *non vide* de **symboles** dont les éléments sont appelés des **lettres**
- Remarque : dans certaines applications, on remplacera la notion **d'alphabet** par la notion de **vocabulaire**
- Un **vocabulaire** sera un ensemble de **mots** (cf. plus loin), pris eux-mêmes comme **symboles de départ**

# Alphabet

- $\{0, 1\}$
- $\{a, b\}$
- $\{a, b, c\}$
- $\{A, B, C, D, E, F, G, H, I, J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z\}$
- $\{\alpha, \beta, \chi, \delta, \varepsilon, \phi, \gamma, \eta, \iota, \varphi, \kappa, \lambda, \mu, \nu, \omicron, \pi, \theta, \rho, \sigma, \tau, \upsilon, \varpi, \omega, \xi, \psi, \zeta\}$

sont des **alphabets** couramment utilisés

# Alphabet

- $\{0, 1\}$ 
  - On peut le considérer comme l'alphabet binaire
- $\{A, B, C, D, E, F, G, H, I, J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z\}$ 
  - On peut le considérer comme l'alphabet français
- $\{\alpha, \beta, \chi, \delta, \varepsilon, \phi, \gamma, \eta, \iota, \varphi, \kappa, \lambda, \mu, \nu, \omicron, \pi, \theta, \rho, \sigma, \tau, \upsilon, \varpi, \omega, \xi, \psi, \zeta\}$ 
  - On peut le considérer comme l'alphabet grec



# Mots

- Un **mot** est une suite finie de **lettres**
- Exemples:
  - 0010111100 est un mot sur  $\{0, 1\}$
  - aaabbb est un mot sur  $\{a, b\}$
  - acababbc est un mot sur  $\{a, b, c\}$
  - BONJOUR est un mot sur  $\{A, \dots, Z\}$
  - $\lambda\omicron\gamma\omicron\sigma$  est un mot sur  $\{\alpha, \dots, \zeta\}$

# Petite précision...

- Une **suite finie** d'éléments d'un ensemble **A** peut se définir de plusieurs manières :

- C'est une application

- $s : \{1, \dots, n\} \rightarrow A$  pour un  $n$  donné,

Exemple:

Avec Alphabet = A

Application  $s(1) = B$ ,  $s(2) = E$ ,  $s(3) = N$  définit le mot BEN.

- C'est un élément du produit cartésien  $A^n$

Exemple

$(B, E, N)$  est un élément de  $A \times A \times A$  (c.-à-d.  $A^3$ )

# Petite précision...

- L'application  $s$  en question, de  $\{1, \dots, n\}$  dans  $A$ , n'est autre que l'application **rang**  
→ elle donne, pour un entier  $i$  tel que  $1 \leq i \leq n$  et pour un certain  $n$ , **la lettre qui, dans le mot, occupe le rang  $n$**
- On se convaincra facilement qu'il est équivalent de se donner un « mot », tel que **abba** et de se donner *l'application* qui indique pour chaque rang quelle est la lettre qui occupe ce rang

# Propriétés des mots - Rang

- Définir un mot est donc équivalent à définir une application «rang », notée  $s: \{1, \dots, n\} \rightarrow \text{alphabet}$
- Exemples
  - $0010111100(1) = ?$   
 $0010111100(1) = 0$
  - $0010111100(2) = ?$   
 $0010111100(2) = 0$
  - $0010111100(3) = ?$   
 $0010111100(3) = 1$
  - $\text{BONJOUR}(4) = ?$   
 $\text{BONJOUR}(4) = J$
  - $\text{BONJOUR}(6) = ?$   
 $\text{BONJOUR}(6) = U$
  - $\text{BONJOUR}(7) = ?$   
 $\text{BONJOUR}(7) = R$

# Propriétés des mots - Longueur

- L'entier  $n$  maximum pour lequel  $s$  est défini s'appelle **la longueur** du mot  $s$
- Exemples
  - **BONJOUR**(7) = R
  - **BONJOUR**(8) = non défini
  - **BONJOUR** est un mot de longueur 7
- **La longueur** d'un mot est la **position** de sa **dernière lettre** ou..
- La longueur d'une chaîne est le nombre de caractères dans la chaîne

# Propriétés des mots – Ensemble de tous les mots

- Soit  $\Sigma$  un alphabet = {a, b, c}
- L'ensemble de **tous les mots** qui peuvent être construits à partir de l'alphabet est noté  $\Sigma^*$
- Les éléments de  $\Sigma^*$  incluent :
  - Longueur 0:  $\epsilon \rightarrow$  ***mot de longueur 0***
  - Longueur 1: a b c  $\rightarrow$  ***mots de longueur 1***
  - Longueur 2: aa ab ac ba bb bc ca cb cc  $\rightarrow$  ***mots de longueur 2***
  - Longueur 3: aaa aab aac aba abb abc aca acb acc  
baa bab bac bba bbb bbc bca bcb bcc  
caa cab cac cba cbb cbc cca ccb ccc  $\rightarrow$  ***mots de longueur 3***
  - ...
  - Longueur  $n$  : ...  $\rightarrow$  ***mots de longueur n***
  - ...
  - Longueur  $\infty$

**$\epsilon$  est unique, inclus dans tout  $\Sigma^*$  quelque soit  $\Sigma$**



# Propriétés des mots – mot vides

- Le mot vide est l'unique chaîne sur  $\Sigma$  de longueur 0, et est notée  $\varepsilon$  ou  $\lambda$
- Soit  $\varepsilon$  le mot vide
  - D'après ce qui précède,  $\varepsilon$  est unique.
  - Soit  $A^*$  l'ensemble des mots sur l'alphabet  $A$ , on a toujours :  $\varepsilon \in A^*$

# Concaténation de mots

- Soit 2 **mots**  $s$  et  $s'$  sur  $A$
- S'ils sont définis par les applications  $s: \{1, \dots, n\} \rightarrow A$  et  $s': \{1, \dots, m\} \rightarrow A$
- La **concaténation** de  $s$  et  $s'$  est notée  $s^{\wedge}s'$
- Le nouveau mot  $s^{\wedge}s'$  est défini par:  
 $s^{\wedge}s': \{1, \dots, n+m\} \rightarrow A$ , définie par:
  - pour tout  $i$ , si  $1 \leq i \leq n$ ,  $s^{\wedge}s'(i) = s(i)$
  - si  $n < i \leq n+m$ ,  $s^{\wedge}s'(i) = s'(i - n)$

# Concaténation de mots - Exemple

- Sur  $\{a, b, c\}$ , **abbac** est un mot, qui peut être défini par l'application  $s$  suivante :  
 $s(1) = a$ ,  
 $s(2) = b$ ,  
 $s(3) = b$ ,  
 $s(4) = a$ ,  
 $s(5) = c$
- Sur  $\{a, b, c\}$ , **bcca** est un autre mot, qui peut être défini par  $s'$  :  
 $s'(1) = b$ ,  
 $s'(2) = c$ ,  
 $s'(3) = c$ ,  
 $s'(4) = a$
- On vérifiera que leur **concaténation**  $s^s'$  correspond au mot :  
**abbacbcca**

# Propriétés de la concaténation

- La concaténation est **associative** :  
 $(A^{\wedge}B)^{\wedge}C = A^{\wedge}(B^{\wedge}C)$

- La concaténation a un élément neutre :  $\varepsilon$

$$\varepsilon^{\wedge}x = x^{\wedge}\varepsilon = x$$

# Stratification

- Parmi tous les mots sur  $A$ , il y a :
  - Les mots de **longueur nulle**, formant l'ensemble  $\{\varepsilon\}$
  - Les mots de **longueur 1**, donnant simplement l'ensemble  $A$  (car on ne fait pas dans ce cas de différence entre *lettre* et *mot d'1 seule lettre*)
  - Les mots de **longueur 2**, formant  $A^2$ ,  
Exemple  
 $A = \{1, 2, 3\}$   
 $A^2 = \{(1,1), (1,2), (1,3), (2,1), (2,2), (2,3), (3,1), (3,2), (3,3)\}$
  - ...
  - Les mots de **longueur  $n$** , formant  $A^n$
  - *etc.*

# Stratification

- Dans l'exemple précédent :

Soit  $\Sigma$  l'alphabet = {a, b, c}

Longueur 0  $\rightarrow \Sigma^0 = \{\varepsilon\}$

Longueur 1:  $\rightarrow \Sigma = \{a, b, c\}$

Longueur 2:

$\rightarrow \Sigma^2 = \{aa, ab, ac, ba, bb, bc, ca, cb, cc\}$

Longueur 3:

$\rightarrow \Sigma^3 = \{aaa, aab, aac, aba, abb, abc, aca, acb, acc, baa, bab, bac, bba, bbb, bbc, bca, bcb, bcc, caa, cab, cac, cba, cbb, cbc, cca, ccb, ccc\}$

...



# Stratification

- $A^*$  (l'ensemble de *tous* les mots sur l'alphabet  $A$ ) peut être noté en utilisant la stratification :

$$A^* = \{\varepsilon\} \cup A \cup A^2 \cup A^3 \dots \cup A^n \dots$$

- Ou bien encore

$$A^* = \bigcup_{n=0}^{\infty} A^n$$

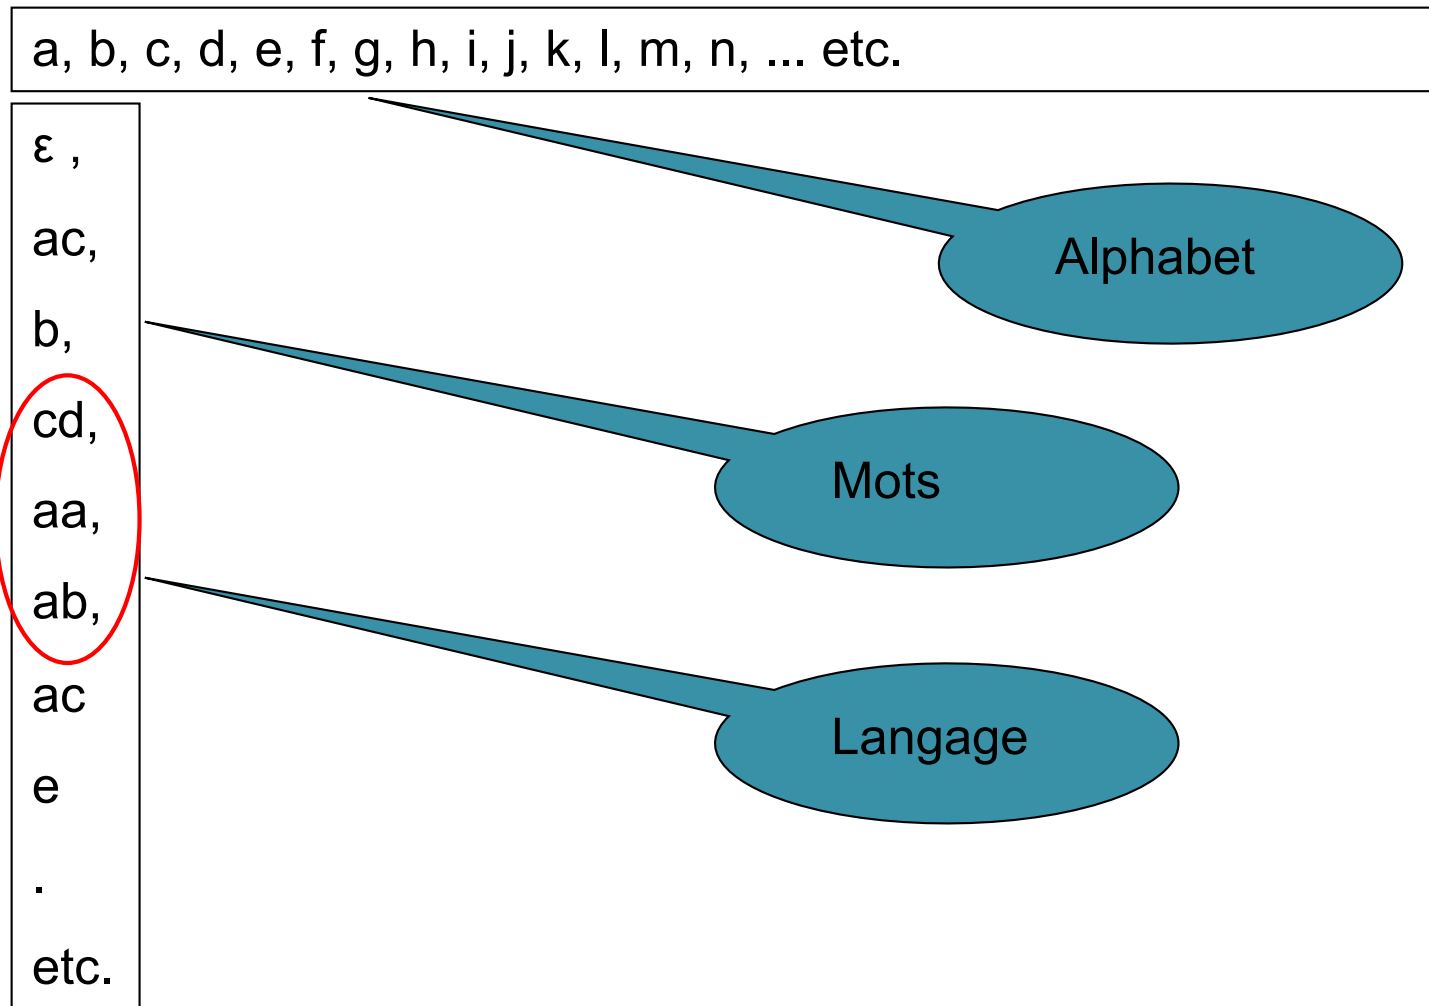
- Avec  $A^0 = \{\varepsilon\}$

# Langages - Définition

- Un **langage sur un alphabet  $A$**  sera défini simplement comme **une partie de  $A^*$**
- Donc, un **sous-ensemble** de  $A^*$  ( $\Sigma^*$ ) est appelé **un langage**
- Ainsi, parmi les langages possibles sur  $A$ :
  - $\emptyset$  est le langage vide
  - $\{\epsilon\}$  est le langage réduit au mot vide
  - $A^*$  est le langage plein

# Langages – Relations entre alphabet, mots, et langages

- Exemple



# Langages – Opérations - **Union**

- Si  $L$  et  $L'$  sont des langages respectivement définis sur les alphabets  $A$  et  $A'$ , l'**union de  $L$  et de  $L'$** , notée  $L \cup L'$ , est un langage sur l'alphabet  $A \cup A'$  qui contient les mots qui sont, soit contenus dans  $L$ , soit contenus dans  $L'$
- $L \cup L' = \{u, \text{ tel que } u \in L \text{ ou } u \in L'\}$
- Exemple:

$$L = \{\text{de}\}$$

$$L' = \{\text{main}\}$$

$$L \cup L' = \{\text{de}, \text{main}\}$$

# Langages – Opérations - **Produit**

- Si  $L$  et  $L'$  sont des langages respectivement définis sur les alphabets  $A$  et  $A'$ , le **produit ou concaténation de  $L$  et de  $L'$** , noté  $L.L'$ , est un langage sur l'alphabet  $A \cup A'$  contenant tous les mots formés d'un mot de  $L$  suivi d'un mot de  $L'$
- $L.L' = \{w = u^v, \text{ tels que } u \in L \text{ et } v \in L'\}$
- Exemple:

$$L = \{\text{de}\}$$

$$L' = \{\text{main}\}$$

$$L.L' = \{\text{demain}\}$$

# Langages – Propriétés des opérations

- Soit sur  $\{a, b, c\}$  les langages:  
 $L = \{aa, bb\}$   
 $L' = \{ca, cb, cc\}$
- On a:  
 $L \cup L' = \{aa, bb, ca, cb, cc\}$   
 $L' \cup L = \{ca, cb, cc, aa, bb\}$   
 $L \cup L' = L' \cup L$   
→ L'union est une opération commutative
- On a:  
 $L.L' = \{aaca, aacb, aacc, bbca, bbcb, bbcc\}$   
 $L'.L = \{caaa, cabb, cbaa, cbba, ccaa, ccbb\}$   
 $L.L' \neq L'.L$   
→ Le produit n'est pas une opération commutative



# Langages – Opérations – **L'étoile de Kleene**

- L'étoile de Kleene est une opération qui **élargit** un langage **unique**
  - Plutôt que de combiner plusieurs langages (comme on le faisait avec le produit), on forme **toutes les concaténations de zéro ou plusieurs mots du même langage**
  - Notez que le mot vide sera un élément du langage élargi ( $L^*$ )

# L'étoile de Kleene

- L'opération de l'étoile de Kleene est notée par “\*”
- Note : nous avons déjà rencontré l'étoile de Kleene en utilisant  $\Sigma^*$  (tous les mots finis qui peuvent être formés à partir de l'alphabet  $\Sigma$ )

# L'étoile de Kleene

Exemple :

- Si  $L_1$  est le langage  $\{y\}$ , alors  $L_1^*$  est le langage formé de la chaîne vide et de toutes les chaînes finies de 'y'

$\{\varepsilon, y, yy, yyy, yyyy, \dots\}$

- Si  $L_2$  est le langage  $\{yy\}$ , alors  $L_2^*$  est le langage formé de la chaîne vide et de toutes les chaînes constituées d'un nombre pair de 'y'

$\{\varepsilon, yy, yyyy, yyyyyy, yyyyyyyy, \dots\}$

# L'étoile de Kleene

- Un autre exercice :  
si  $L = \{0, 1\}$ ,

$L^* = \{\epsilon, 0, 1, 00, 01, 10, 11, 000, 001, 010, 011, \dots\}$ .

# L'étoile de Kleene

- On peut définir également l'opération suivante, appelée opération de **fermeture (de Kleene, ou itérative...)**

$$L^* = \{w \in A^*, \text{ tel que } \exists n \geq 0, \exists w_1, w_2, \dots, w_n \in A^*, w = w_1 \wedge w_2 \dots \wedge w_n\}$$

*c.-à-d.: Toutes les concaténations possibles des mots de ce langage*

# L'étoile de Kleene - Exemple

- Un autre exemple :

Soit  $L = \{ab, ba\}$  sur  $A = \{a, b\}$

$L^* = \{\varepsilon, ab, ba, abab, abba, baab, baba, ababab, ababba, abbaab, abbaba, baabab, baabba, babaab, bababa, \dots\}$



# Langage des mots d'une lettre

- Soit  $L$  le langage des **mots d'une lettre** sur  $A$ , on vérifiera bien sûr que  $L^* = A^*$  autrement dit, l'étoile de « $A^*$ » (ensemble des mots sur  $A$ ) est bien l'étoile de Kleene ! (ouf!)

- Exemple:

symboles

mots

$A = \{a, b\}$ , alors  $A^* = \{\varepsilon, a, b, aa, ab, ba, bb, \dots\}$

Si  $L = \{a, b\}$ , alors  $L^* = \{\varepsilon, a, b, aa, ab, ba, bb, \dots\}$

mots

mots

# L'étoile de Kleene - Propriété

- On peut vérifier que, comme pour  $A^*$ , on a la décomposition générale suivante :

$$L^* = \bigcup_{n=0}^{\infty} L^n = \{\varepsilon\} \cup L \cup L^2 \cup L^3 \cup L^4 \cup L^5 \dots$$

- Où, bien entendu,  $L^n = L.L...L$  (n fois)
- On peut donc avoir une notation stratification (par longueur de mots) pour les langages

# Propriétés des langages -

## Associativité

- Soit A, B et C, 3 langages. On a (associativité) :
  - $A.(B.C) = (A.B).C$
  - $A \cup (B \cup C) = (A \cup B) \cup C$
- Exemple:  
     $L = \{a, b\}$   
     $G = \{c\}$   
     $H = \{d, e\}$
- $L.(G.H) = \{a, b\}.\{c^d, c^e\}$   
     $= \{a^c, b^c\}.\{d, e\}$   
     $= \{a^c d, a^c e, b^c d, b^c e\}$
- $(L.G).H = \{a^c, b^c\}.\{d, e\}$   
     $= \{a^c d, a^c e, b^c d, b^c e\}$   
     $= \{a^c d, a^c e, b^c d, b^c e\}$

# Propriétés des langages – Distributivité et autres

- Soit  $G$ ,  $H$  et  $F$ , 3 langages. On a (distributivité) :
  - $G.(H \cup F) = G.H \cup G.F$
- autres
  - $L.\emptyset = \emptyset$        $L \cup \emptyset = L$
  - $L.\{\epsilon\} = L$
  - $\emptyset^* = \{\epsilon\}$  **Convention**
  - $\{\epsilon\} \cup L.L^* = L^*$

## Exemple d'utilisation de la distributivité

- Prouver que  $\{\varepsilon\} \cup L.L^* = L^*$ 
  - On a  $L^* = \{\varepsilon\} \cup L \cup L^2 \cup L^3 \dots \cup L^n \dots$
  - Donc  $L.L^* = L.(\{\varepsilon\} \cup L \cup L^2 \cup L^3 \dots \cup L^n \dots)$
  - Par distributivité,  $L.L^* = L.\{\varepsilon\} \cup L.L \cup L.L^2 \cup \dots \cup L.L^n \dots = L \cup L^2 \cup L^3 \dots \cup L^n \dots$
  - Donc  $\{\varepsilon\} \cup L.L^* = \{\varepsilon\} \cup L \cup L^2 \cup L^3 \dots \cup L^n \dots = L^*$
  - cqfd !

# Langages réguliers

- Un **langage régulier** sur un alphabet  $A$  est :
  - ou bien :  $\emptyset$
  - ou bien :  $\{\varepsilon\}$
  - ou bien :  $\{x\}$  pour n'importe quel  $x \in A$   
(aussi appelé un langage '**singleton**' – un ensemble avec exactement un élément)
  - ou bien : un **langage quelconque** obtenu à partir de deux langages réguliers par **union** ou par **produit**
  - ou bien : un langage quelconque obtenu à partir d'un langage régulier par **fermeture de Kleene**



# Langages réguliers

- Exemples typiques :
  - le langage formé de tous les mots de l'alphabet  $\{a, b\}$
  - le langage formé de tous les mots de la forme : plusieurs 'a' suivis de plusieurs 'b'
  - le langage contenant un nombre pair de 'a',

# Exemples - Langages réguliers

- Par construction, voici des langages réguliers sur  $\{a,b,c\}$  :
  - $\{a\} \cup \{b\}$
  - $(\{a\} \cup \{b\})^*$
  - $\{a\}\{a\}\{a\}$
  - $\{a\}\{a\}\{a\} (\{a\} \cup \{b\})^*$
  - $(\{\varepsilon\} \cup \{a\}\{a\})^*$
  - $(\{\varepsilon\} \cup \{a\}\{a\})^* \{b\}\{b\}\{b\} (\{a\} \cup \{b\})^*$
- Mais que sont-ils exactement ?

# Exemples - Langages réguliers

- $\{a\} \cup \{b\} = \{a, b\}$
- $(\{a\} \cup \{b\})^* = \{a, b\}^*$
- $\{a\}\{a\}\{a\} = \{aaa\}$
- $\{a\}\{a\}\{a\} (\{a\} \cup \{b\})^* =$  ensemble des mots sur  $\{a, b\}$  qui commencent par  $aaa$
- $(\{\varepsilon\} \cup \{a\}\{a\})^* =$  ensemble des mots constitués d'un nombre pair de  $a$  (y compris 0 'a' possible)
- $(\{\varepsilon\} \cup \{a\}\{a\})^* \{b\}\{b\}\{b\} (\{a\} \cup \{b\})^* =$  ensemble des mots sur  $\{a, b\}$  commençant par un nombre pair de  $a$ , y compris aucun, suivis de trois  $b$

# Exemples - Langages réguliers

- L'ensemble des représentations en binaire des entiers **pairs** est un **langage régulier** sur  $\{0, 1\}$ 
  - car il s'écrit:  $(\{0\} \cup \{1\})^*0$
- L'ensemble des mots se terminant en '**tion**' est un **langage régulier** sur  $\{a, b, \dots, z\}$ 
  - car il s'écrit:  $(\{a\} \cup \{b\} \cup \{c\} \cup \dots \{z\})^* \{t\} \{i\} \{o\} \{n\}$
- L'ensemble des **mots de 3 lettres** sur  $\{a, b\}$  est un **langage régulier**
  - car il s'écrit:  
 $\{a\}\{a\}\{a\} \cup \{b\}\{a\}\{a\} \cup \{a\}\{b\}\{a\} \cup \{a\}\{a\}\{b\} \cup$   
 $\{a\}\{b\}\{b\} \cup \{b\}\{a\}\{b\} \cup \{b\}\{b\}\{a\} \cup \{b\}\{b\}\{b\}$

# Expressions régulières

- Les expressions régulières permettent de représenter un langage régulier
- On peut voir les expressions régulières comme une **notation compacte** pour les langages réguliers
  - $(\{\varepsilon\} \cup \{a\}a)^* \{b\}bb (\{a\} \cup \{b\})^*$  n'est pas compacte !

# Expressions régulières

- Les **expressions régulières** servent à **désigner** les langages réguliers
  - $\emptyset$ ,  $\varepsilon$  et toute lettre  $x \in A$  sont des expressions régulières sur  $A$ ,
  - Si  $\alpha$  et  $\beta$  sont des expressions régulières sur  $A$ , alors:
    - $\alpha + \beta$  et  $\alpha\beta$  sont des expressions régulières sur  $A$
    - $(\alpha)^*$  est aussi une expression régulière sur  $A$
  - Note : ‘+’ est la notation pour l’union dans les expressions régulières



# Expressions régulières

- Des exemples d'expressions régulières sur  $\{a,b,c\}$  :
  - $a+b$
  - $(a+b)^*$
  - $aaa$
  - $aaa(a+b)^*$
  - $(\varepsilon+aa)^*$
  - $(\varepsilon+aa)^*bbb(a+b)^*$

# Expressions régulières

- $a+b$  désigne  $\{a\} \cup \{b\}$
- $(a+b)^*$  désigne  $(\{a\} \cup \{b\})^*$
- $aaa$  désigne  $\{a\}\{a\}\{a\}$
- $aaa(a+b)^*$  désigne  $\{a\}\{a\}\{a\} (\{a\} \cup \{b\})^*$
- $(\varepsilon+aa)^*$  désigne  $(\{\varepsilon\} \cup \{a\}\{a\})^*$
- $(\varepsilon+aa)^*bbb(a+b)^*$  désigne  $(\{\varepsilon\} \cup \{a\}\{a\})^* \{b\}\{b\}\{b\} (\{a\} \cup \{b\})^*$

# Expressions régulières - Propriétés

- On retrouve sur les expressions régulières. les propriétés induites par les langages réguliers :
- **associativité**
  - $\alpha(\beta\gamma) = (\alpha\beta)\gamma$
  - $\alpha+(\beta+\gamma) = (\alpha+\beta)+\gamma$
- **distributivité**
  - $\alpha(\beta+\gamma) = \alpha\beta + \alpha\gamma$
- **autres**
  - $\alpha\emptyset = \emptyset \quad \alpha+\emptyset = \alpha$
  - $\alpha\varepsilon = \alpha$
  - $\emptyset^* = \varepsilon$
  - $\varepsilon + \alpha\alpha^* = \alpha^*$

Avec  $\alpha, \beta, \gamma$  des expressions régulières

# Expressions régulières - autres propriétés

- $(\alpha + \beta)^* = (\alpha^* + \beta^*)^* = (\alpha^* \beta^*)^* = (\alpha^* \beta)^* \alpha^* = \alpha^* (\beta \alpha^*)^*$
- $\alpha (\beta \alpha)^* = (\alpha \beta)^* \alpha$
- ...

# Expressions régulières - Exemples / Exercices

- $ab^*$
- $a^*b$  (Exercice)
- $(a+b)$
- $(a+b)^*$  (Exercice)

# Expressions régulières - Exemple

$a^*ba^*(ba^*ba^*)^*$

c'est le langage des mots ayant un nombre impair de b



# Expressions régulières - Exemples

- Désigner par une expression régulière:
  - L'ensemble des représentations en binaires d'entiers pairs:  
 $(0+1)^*0$
  - L'ensemble des mots ayant un nombre pair de lettres sur  $\{a, b\}$ :  
 $(aa+bb+ab+ba)^*$
  - L'ensemble des mots qui contiennent au moins une fois trois 'a' qui se suivent:  
 $(a+b)^*aaa(a+b)^*$
  - L'ensemble des mots de 4 lettres sur  $\{0, 1\}$ :  
 $(0+1)(0+1)(0+1)(0+1)$

# Expressions régulières - Exercice

- Exprimer par une **expression régulière** la plus réduite possible la conjugaison en français, au *présent*, au *futur* et à *l'imparfait* du verbe *chanter*